Haute Ecole en Hainaut

Projet de bioinformatique
D'AlphaFold2 à AlphaFold3

Auteur :
Guillaume Rosin

Enseignant :
Vincent Branders

Résumé

AlphaFold2 a résolu en grande partie le problème du repliement des protéines isolées, en exploitant les signaux de coévolution d'un alignement multiple de séquences. Mais il ne voit que des protéines : ni ADN, ni ARN, ni ions, ni ligands. AlphaFold3 (2024) lève cette limite en prédisant des complexes de toutes ces molécules, grâce à une architecture remaniée (Pairformer, module de diffusion sur les atomes). Ce projet explique ce que faisait AlphaFold2, pourquoi il est aujourd'hui dépassé, et comment utiliser AlphaFold3. Un déploiement d'AlphaFold2 (ColabFold 1.5.5 dans Docker, sur CPU) sert de référence : la calmoduline humaine (149 résidus) y est prédite avec deux lobes fiables (pLDDT moyen 82,8) dont l'orientation relative reste incertaine (PAE d'environ 20 Å), et sans les ions Ca^{2+} qu'elle fixe. AlphaFold3, utilisé via AlphaFold Server faute de GPU, prédit l'ubiquitine humaine avec une confiance très élevée, à l'exception de sa queue C-terminale flexible.

27 octobre 2026

1 Introduction

Le défi. Les protéines sont des éléments fondamentaux du vivant. Chacune possède une forme tridimensionnelle qui détermine sa fonction : catalyser une réaction, transporter une molécule, contracter un muscle. Or la séquence d'acides aminés d'une protéine se lit facilement, alors que sa structure demande des expériences longues et coûteuses (cristallographie, RMN, cryo-microscopie électronique). Prédire la structure à partir de la séquence, c'est le « problème du repliement », ouvert depuis une cinquantaine d'années [8].

D'AlphaFold2 à AlphaFold3. En 2020, **AlphaFold2**, développé par Google DeepMind [17], a résolu en grande partie ce problème pour les protéines isolées. Mais dans la cellule, une protéine fonctionne rarement seule : elle se lie à de l'ADN, à de l'ARN, à des ions, à des cofacteurs ou à des médicaments. AlphaFold2 ne voit rien de tout cela. En mai 2024, **AlphaFold3** [1] a élargi la prédiction à presque toutes les molécules du vivant, réunies dans un même complexe, grâce à une architecture profondément remaniée.

Objectif du projet. Le projet portait au départ sur AlphaFold2. Il a été réorienté vers AlphaFold3, qui le remplace pour la plupart des usages. Le rapport répond à trois questions :

1. **Que faisait AlphaFold2**, et comment ?
2. **Pourquoi est-il aujourd'hui dépassé**, et qu'apporte AlphaFold3 ?
3. **Comment utiliser AlphaFold3 et interpréter ses résultats** ?

Le déploiement d'AlphaFold2 (ColabFold dans Docker) est conservé comme *expérience de référence* : sa prédiction de la calmoduline montre concrètement l'une de ses limites. AlphaFold3 est ensuite utilisé via AlphaFold Server sur une protéine test, l'ubiquitine humaine, et ses nouveaux scores de confiance sont analysés.

2 Ce que faisait AlphaFold2

Un modèle d'apprentissage profond. AlphaFold2 ne simule pas la physique du repliement. C'est un **réseau de neurones** qui a *appris* la relation entre séquence et structure à partir des structures expérimentales de la **Protein Data Bank** (PDB), une base publique qui contient aujourd'hui plus de 215 000 structures [3]. Il peut utiliser des structures connues comme gabarits, mais il n'en a pas besoin, et il prédit aussi des repliements jamais observés [8].

Entrée et sortie. L'utilisateur fournit uniquement la **séquence** d'une protéine (format FASTA). AlphaFold2 renvoie les **coordonnées 3D** de ses atomes lourds (fichier PDB ou mmCIF), accompagnées de **mesures de confiance**.

Le MSA et la coévolution. La première étape consiste à rechercher, dans de grandes bases de séquences, des protéines *homologues* (issues d'un ancêtre commun) et à les aligner : c'est l'**alignement multiple de séquences** (MSA). Le MSA apporte deux informations structurales :

- la **conservation** : une position qui ne varie jamais est probablement essentielle (cœur hydrophobe, site actif) ;
- la **coévolution** : si deux résidus sont en contact, une mutation de l'un est souvent compensée par une mutation de l'autre. Deux colonnes qui varient *ensemble* indiquent donc deux résidus probablement proches dans l'espace [8].

Plus le MSA est profond et diversifié, plus ces signaux sont fiables. À l'inverse, une protéine « orpheline », sans homologues, est en général mal prédite.

Les grandes étapes. La figure 1 résume le processus :

1. **Recherche d'homologues** (MSA) et, en option, de structures similaires (*gabarits*) ;
2. **Evoformer** (48 blocs) : le réseau fait circuler l'information entre le MSA et une « représentation de paires », qui décrit pour chaque couple de résidus (i, j) leur relation spatiale probable ;
3. **Module de structure** : il place chaque résidu comme un petit repère rigide (position et orientation du squelette), puis ajoute les chaînes latérales par leurs angles de torsion ;
4. **Recyclage** : la structure obtenue est réinjectée dans le réseau (3 fois par défaut) pour l'affiner.

Des mesures de confiance. Une prédiction n'est pas une mesure : sa qualité varie d'une protéine à l'autre et d'une région à l'autre. AlphaFold2 a donc été entraîné à *estimer sa propre erreur*. Il produit un score local par résidu, le **pLDDT**, et une erreur relative entre paires de résidus, la **PAE** (section 8).

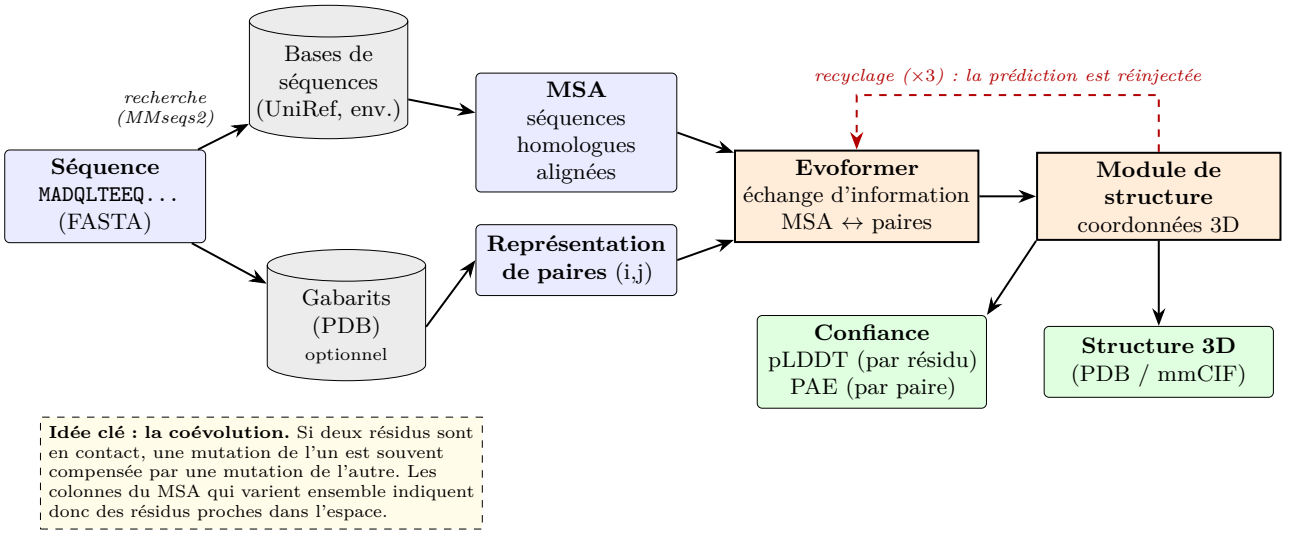


FIGURE 1 – Schéma du fonctionnement général d'AlphaFold2 (réalisation personnelle, d'après [17, 8]).

Un tournant pour la biologie structurale. En 2020, AlphaFold2 a remporté la 14e édition de CASP, compétition où l'on prédit des structures résolues mais pas encore publiées. Les organisateurs ont jugé le problème « en grande partie résolu pour les protéines individuelles » [18]. Le code et les poids sont libres [13], et la base **AlphaFold DB** fournit gratuitement des structures précalculées pour la quasi-totalité des ∼200 millions de protéines d'UniProt [25]. Une variante, **AlphaFold-Multimer** [11], a ensuite permis de prédire des complexes formés de *plusieurs protéines*.

3 Pourquoi AlphaFold2 est aujourd'hui dépassé

AlphaFold2 reste un excellent outil pour une protéine isolée. Mais ses limites tiennent à sa conception même, et AlphaFold3 les lève presque toutes.

Il ne voit que des protéines. AlphaFold2 ne connaît que les 20 acides aminés standards. Il ignore l'ADN, l'ARN, les ions métalliques, les cofacteurs (hème, ATP, NAD), les médicaments et les modifications post-traductionnelles (phosphorylation, glycosylation). Or ces partenaires changent souvent la structure : la prédiction de la calmoduline réalisée dans ce projet en est un exemple. Cette protéine fixe quatre ions Ca^{2+} qui modifient la conformation de ses lobes, mais AlphaFold2 la prédit *sans* ses ions (section 7). Pour étudier une interaction protéine–ligand, il fallait enchaîner AlphaFold2 avec un logiciel de docking séparé.

Une architecture taillée pour les protéines. Le module de structure d'AlphaFold2 raisonne en « résidus » : un repère rigide pour le squelette, puis des angles de torsion pour les chaînes latérales. Ce codage est propre aux acides aminés et ne s'étend pas à une petite molécule quelconque. De plus, la géométrie obtenue n'est pas toujours chimiquement propre, d'où une étape optionnelle de relaxation physique (Amber) après la prédiction [17].

Une forte dépendance au MSA. L'Evoformer consacre une grande partie de son calcul au MSA. La qualité de la prédiction dépend donc fortement de la profondeur de l'alignement, et le pipeline officiel exige jusqu'à 2,6 To de bases de séquences [13].

Les complexes, un ajout tardif. AlphaFold-Multimer [11] gère plusieurs chaînes protéiques, mais reste limité aux protéines. Ses performances sur les interfaces difficiles, comme les complexes anticorps–antigène, restent modestes [1].

En résumé, AlphaFold2 répond à la question « quelle est la forme de cette protéine, seule ? ». La biologie et la pharmacologie demandent plutôt « comment cette protéine s'assemble-t-elle avec ses partenaires ? ». C'est la question à laquelle répond AlphaFold3.

4 AlphaFold3 : ce qui change

Entrée : une liste de molécules. AlphaFold3 [1] prend en entrée une *liste d'entités*, chacune avec son nombre de copies : chaînes protéiques, ADN, ARN, ligands (donnés par leur code dans le dictionnaire chimique de la PDB, ou par une formule SMILES), ions, et résidus modifiés. Il renvoie la structure 3D de *tout le complexe*, à l'échelle de l'atome.

Une architecture remaniée. La figure 2 présente les grandes étapes. Trois changements comptent :

- **Des jetons plutôt que des résidus.** Chaque résidu de protéine ou nucléotide forme un jeton ; chaque atome d'un ligand forme un jeton à lui seul. Le réseau traite ainsi toutes les molécules de la même façon.
- **Un MSA moins central.** Le MSA n'est plus traité que par un petit « module MSA » de 4 blocs. Le tronc du réseau, le **Pairformer** (48 blocs), remplace l'Evoformer et travaille uniquement sur la représentation de paires et sur une représentation par jeton, sans le MSA (voir l'annexe A pour une explication détaillée et un exemple).
- **Un module de diffusion.** Au lieu de repères et d'angles de torsion, AlphaFold3 prédit directement les coordonnées de *tous les atomes*. Comme les générateurs d'images, il part d'un nuage aléatoire qu'il « débruite » progressivement, guidé par le Pairformer. Ce procédé n'a besoin d'aucune règle propre aux acides aminés, ce qui lui permet de placer n'importe quelle molécule. En relançant la diffusion avec des graines différentes, on obtient plusieurs structures possibles.

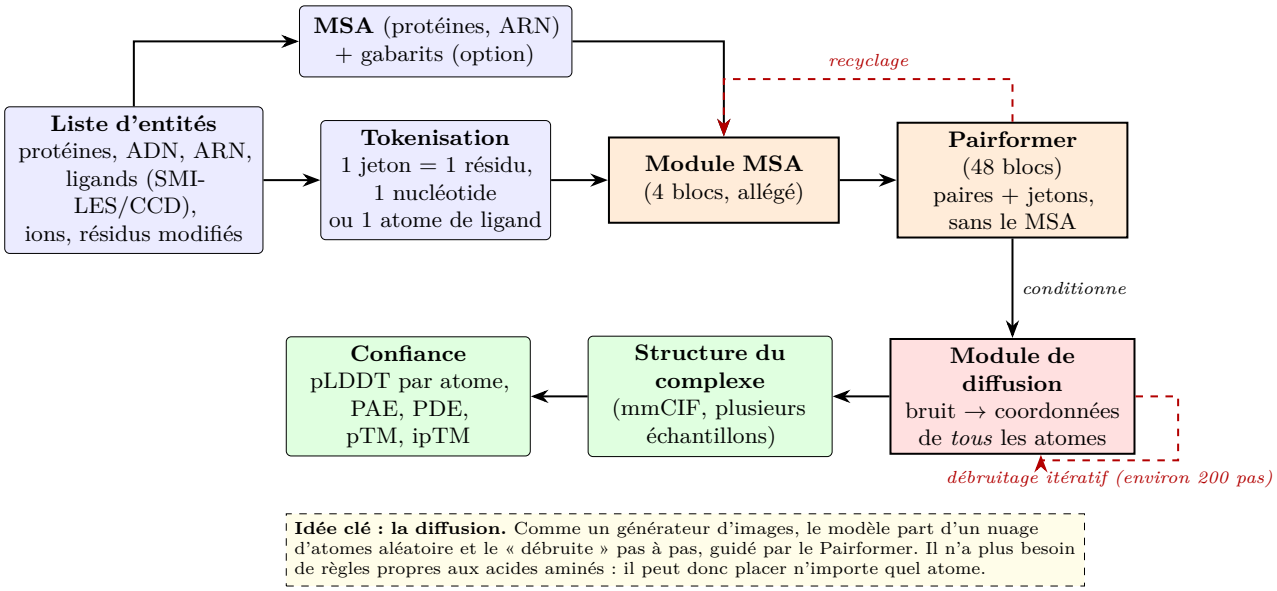


FIGURE 2 – Schéma du fonctionnement général d'AlphaFold3 (réalisation personnelle, d'après [1]).

Des scores de confiance étendus. AlphaFold3 conserve les scores d'AlphaFold2 et les adapte aux complexes [1, 15] :

- le **pLDDT** est calculé *par atome* et non plus par résidu ; pour un ligand, il ne mesure que les erreurs entre ses atomes et les polymères voisins ;
- la **PAE** est définie entre jetons ; pour un ligand, un repère de référence est construit pour chaque atome à partir de ses voisins ;
- la **PDE** (*predicted distance error*) estime l'erreur sur la distance entre deux jetons ;
- le **pTM** juge le repliement global : au-dessus de 0,5, la forme d'ensemble est probablement correcte [26] ;
- l'**ipTM** juge la position relative des chaînes dans le complexe : au-dessus de 0,8, la prédiction est fiable ; en dessous de 0,6, elle est probablement fausse ; entre les deux, c'est une zone grise.

Des performances supérieures. Sur le banc d'essai PoseBusters [4], qui compare des poses de ligands à des structures expérimentales, AlphaFold3 place correctement (à moins de 2 Å) environ 76 % des ligands, sans recevoir la structure de la protéine. Il dépasse ainsi les outils de docking classiques, qui en ont pourtant besoin. Il améliore aussi nettement la prédiction des complexes protéine–acides nucléiques et anticorps–antigène par rapport à AlphaFold-Multimer, et reste au moins aussi bon qu'AlphaFold2 sur les protéines seules [1]. Pour la première fois, un modèle généraliste rivalise avec des outils spécialisés.

	AlphaFold2 (2020–2021)	**AlphaFold3 (2024)**
Molécules	Protéines seules (complexes protéiques via Multimer)	Protéines, ADN, ARN, ligands, ions, résidus modifiés
Unité de base	Résidu	Jeton (résidu, nucléotide ou atome de ligand)
Tronc du réseau	Evoformer (48 blocs, MSA au centre)	Module MSA (4 blocs) + Pairformer (48 blocs)
Construction 3D	Module de structure (repères + torsions), relaxation Amber optionnelle	Module de diffusion, directement sur les atomes
Confiance	pLDDT par résidu, PAE, pTM (ipTM avec Multimer)	pLDDT par atome, PAE, PDE, pTM, ipTM
Licence	Code et poids libres (Apache 2.0, CC BY 4.0)	Code libre ; poids sur demande, usage académique non commercial
Accès simple	ColabFold, AlphaFold DB	AlphaFold Server (navigateur)

Table 1 – Comparaison d'AlphaFold2 et d'AlphaFold3.

5 Choix technique

Le tableau 2 compare les solutions envisagées. La machine disponible est un PC Linux (Debian 12, 12 cœurs, 14 Go de RAM, **sans GPU NVIDIA**) sur lequel Docker est installé.

	AlphaFold Server (AF3) [15]	**AlphaFold3 local** [14]	**ColabFold local, Docker (AF2)** [20]	**AlphaFold2 officiel** [13]
À installer	Rien (navigateur, compte Google)	Docker, pilotes NVIDIA, code DeepMind, poids sur demande	Docker + image ColabFold (~10 Go) + poids (~5 Go)	Docker, pilotes NVIDIA, scripts DeepMind
Calcul	Serveurs Google	Local	Local (CPU ou GPU)	Local
Ressources	Aucune localement	GPU obligatoire (A100/H100 80 Go conseillé ; 16 Go limite à 1 280 jetons)	CPU suffisant pour $<$ 300 résidus	GPU recommandé, $\geq$ 64 Go RAM
Bases de données	Aucune	~630 Go	Aucune : MSA via serveur MMseqs2	~2,6 To, ou ~500 Go en `reduced_dbs`
Avantages	Immédiat, AF3 complet, gratuit	Tous les ligands, scriptable, pas de quota	Reproductible, scriptable	Pipeline de référence, hors ligne
Inconvénients	Quota journalier (30 tâches), pas d'API, liste de ligands restreinte, non commercial	Impossible sans GPU ; licence stricte, poids non redistribuables	AF2 seulement ; lent sur CPU	AF2 seulement ; irréaliste sur la machine disponible

Table 2 – Comparaison des solutions envisagées.

Solution retenue pour AlphaFold3 : AlphaFold Server. L'installation locale d'AlphaFold3 exige un GPU récent, absent de la machine disponible : elle est exclue. AlphaFold Server [15] donne accès gratuitement au modèle complet depuis un navigateur, pour un usage non commercial. Son quota (30 tâches par jour, constaté à la connexion) suffit largement pour ce projet. Ses limites sont l'absence d'API, qui empêche l'automatisation, et une liste de ligands plus restreinte que la version locale.

Référence AlphaFold2 : ColabFold 1.5.5 dans Docker. Pour comparer, le déploiement d'AlphaFold2 a été conservé. ColabFold [21] utilise *les mêmes réseaux et les mêmes poids* qu'AlphaFold2 ; il remplace seulement la construction du MSA (2,6 To de bases) par une recherche MMseqs2 [22] sur un serveur public. Il tourne sur CPU, dans un environnement figé par Docker.

AlphaFold2 officiel en mode `reduced_dbs`. Il est aussi possible de déployer l'installation officielle de DeepMind [13]. Le disque ne permet pas d'accueillir les ~2,6 To de la configuration complète : il faut donc utiliser l'option `--db_preset=reduced_dbs`. Elle ne modifie que la construction du MSA ; le réseau, ses poids et la prédiction restent identiques. En mode complet, AlphaFold interroge UniRef90 et MGnify avec JackHMMER, puis BFD (~1,8 To, en partie métagénomique) et UniRef30 (~200 Go) avec HHblits. En mode `reduced_dbs`, ces deux grosses bases sont remplacées par **small BFD** (~17 Go), un sous-ensemble de BFD débarrassé de la

plupart de ses séquences redondantes. L'alignement est un peu moins riche, ce qui pénalise surtout les protéines « orphelines » ; pour la grande majorité des protéines, la différence est faible, et la recherche est plus rapide.

6 Mise en œuvre

6.1 Prérequis

Le tableau 3 résume ce dont il faut disposer avant de commencer. Les versions indiquées sont celles qui ont été testées.

	AlphaFold3 (AlphaFold Server)	**AlphaFold2 (ColabFold dans Docker)**
Système	N'importe lequel, avec un navigateur récent	Linux (testé : Debian 12, noyau 6.12), processeur x86_64
Compte	Compte Google	Aucun
Logiciels	Aucun	Docker (testé : 29.8.1), utilisable sans `sudo` (groupe `docker`) ; Python 3.11 avec numpy et matplotlib pour l'analyse
Matériel	Aucun	CPU suffisant (testé : 12 cœurs, 14 Go de RAM) ; GPU NVIDIA facultatif
Disque	Aucun	~20 Go (image Docker ~10 Go, poids 5,3 Go)
Réseau	Connexion Internet	Connexion Internet : téléchargements initiaux, puis MSA calculé par le serveur `api.colabfold.com` à chaque prédiction

TABLE 3 – Prérequis des deux solutions déployées.

6.2 AlphaFold3 via AlphaFold Server

Installation. Aucune : il suffit de se connecter sur `https://alphafoldserver.com/` avec un compte Google et d'accepter les conditions d'utilisation. L'interface est en anglais ; le compteur « Remaining jobs » indique le quota du jour (30).

Soumettre une nouvelle séquence.

1. Laisser « Entity type » sur *Protein* et « Copies » sur 1, puis coller la séquence dans le champ « Paste sequence or fasta » (séquence brute ou format FASTA).
2. Pour un complexe, cliquer sur « Add entity » et choisir une autre chaîne, de l'ADN, de l'ARN, un ligand ou un ion : c'est là que se voit la différence avec AlphaFold2.
3. Cliquer sur « Continue and preview job », nommer la tâche, puis cliquer sur « Confirm and submit job ».
4. La tâche apparaît dans l'historique avec une icône de chargement (filtre « In progress »), puis passe dans « Completed » quand elle est terminée (quelques minutes pour une petite protéine).

Résultats. Le résultat s'affiche directement dans le navigateur : structure 3D colorée par pLDDT, matrice PAE, pTM et ipTM. Le bouton « Download », en haut de la page, fournit une archive ZIP. Ses fichiers principaux sont les suivants (`<nom>` est le nom donné à la tâche) :

— `fold_<nom>_model_0.cif` à `model_4.cif` : les 5 structures prédites (format mmCIF), le modèle 0 étant le mieux classé ;
— `fold_<nom>_summary_confidences_*.json` : les scores globaux de chaque modèle (pTM, ipTM, score de classement, fraction désordonnée, présence de collisions) ;
— `fold_<nom>_full_data_*.json` : les scores détaillés (pLDDT par atome, matrice PAE, probabilités de contact) ;
— `fold_<nom>_job_request.json` : la requête soumise, utile pour la traçabilité et pour relancer la même tâche.

Difficultés et points d'attention.

— **Pas d'automatisation** : aucune API n'est proposée ; chaque tâche se soumet à la main, ce qui rend les séries de prédictions fastidieuses.
— **Quota** : 30 tâches par jour. Il faut donc préparer les soumissions plutôt que procéder par essais successifs.
— **Ligands limités** : seule une liste restreinte de ligands et d'ions est proposée ; un médicament quelconque (formule SMILES) n'est accepté que par la version locale.

6.3 AlphaFold2 via ColabFold (référence)

Installation, dans l'ordre. Les commandes exactes figurent dans le `README.md` du dépôt :

1. vérifier que Docker fonctionne sans `sudo` : `docker run --rm hello-world` ;
2. télécharger l'image, dans une version figée :
   `docker pull ghcr.io/sokrypton/colabfold:1.5.5-cuda12.2.2` ;
3. télécharger les poids d'AlphaFold2 (5,3 Go, une seule fois) avec `python -m colabfold.download`, exécuté dans le conteneur, vers un dossier `cache/` monté en volume ; `scripts/predict.sh` le fait automatiquement s'ils sont absents ;
4. installer les dépendances Python de l'analyse : `pip install -r scripts/requirements.txt`.

Soumettre une nouvelle séquence.

1. Créer un fichier FASTA dans `data/`, avec **un en-tête court** et une seule séquence protéique. Par exemple, depuis UniProt :
   ```
   curl -s https://rest.uniprot.org/uniprotkb/P0DP23.fasta \
   | sed '1s/.*/>P0DP23/' > data/P0DP23.fasta
   ```
2. Lancer la prédiction : `scripts/predict.sh data/P0DP23.fasta`. Le script exécute `colabfold_batch --num-models 5` dans le conteneur : MSA via MMseqs2, puis prédiction par les 5 modèles AlphaFold2. Il ajoute `--gpus all` si un GPU est détecté.
3. Analyser : `python scripts/analyse.py results/P0DP23 -o figures/P0DP23`, qui extrait le pLDDT et la PAE et produit les figures dans `figures/P0DP23/`.

Résultats. Les résultats sont écrits dans `results/<nom>/` et le journal complet, avec la durée, dans `logs/<nom>.log`. Les fichiers importants sont décrits au tableau 4 (section 7).

Difficultés rencontrées et solutions.

- **Pas de GPU** : JAX bascule automatiquement sur le CPU. Le calcul fonctionne, mais il est lent : 1 h 57 pour 149 résidus et 5 modèles.
- **Fichiers appartenant à `root`** : Docker écrit en `root` par défaut ; il faut le lancer avec `--user $(id -u):$(id -g) -e HOME=/tmp` (déjà fait dans `predict.sh`).
- **Noms de fichiers très longs** : ColabFold nomme les sorties d'après l'en-tête FASTA complet ; il faut le raccourcir (`>P0DP23`).
- **Mémoire** : les avertissements `Allocation exceeds 10% of free system memory` sont sans conséquence ; la consommation plafonne à environ 4 Go.
- **Accès à Docker refusé** (`permission denied ... docker.sock`) : l'utilisateur doit être ajouté au groupe `docker` (`sudo usermod -aG docker $USER`), puis se reconnecter.

6.4 AlphaFold2 officiel en mode `reduced_dbs`

Cette installation n'est réaliste que sur une machine plus puissante (GPU recommandé, $\geq$ 64 Go de RAM, ~500 Go de disque). Les étapes, dans l'ordre, sont celles du dépôt de DeepMind [13] :

1. cloner le dépôt : `git clone https://github.com/google-deepmind/alphafold.git` ;
2. télécharger les bases réduites et les poids (nécessite `aria2c`) :
   `scripts/download_all_data.sh <DOSSIER_BASES> reduced_dbs` ;
3. construire l'image Docker : `docker build -f docker/Dockerfile -t alphafold .` ;
4. installer le lanceur : `pip install -r docker/requirements.txt` ;
5. lancer une prédiction :
   ```
   python docker/run_docker.py --fasta_paths=séquence.fasta --db_preset=reduced_dbs \
   --data_dir=<DOSSIER_BASES> --output_dir=<SORTIE> --max_template_date=2022-01-01
   ```
   (ajouter `--use_gpu=false` sur une machine sans GPU).

Les résultats sont écrits dans `<SORTIE>/<nom>/` : `ranked_0.pdb` est la meilleure structure, `ranking_debug.json` donne le classement des 5 modèles, les fichiers `result_model_*.pkl` contiennent les scores (pLDDT, PAE), et le dossier `msas/` les alignements. La principale difficulté est l'espace disque : la configuration complète (~2,6 To) ne tient pas sur la machine disponible, d'où le mode `reduced_dbs`.

6.5 Limites de la solution déployée

La solution fonctionne dans les conditions du projet, mais plusieurs situations la mettraient en défaut :

— **Serveurs externes indisponibles.** ColabFold dépend du serveur public `api.colabfold.com` pour le MSA, et AlphaFold3 entièrement d'AlphaFold Server. Si l'un d'eux est arrêté, saturé ou limité, la prédiction devient impossible. Pour ColabFold, il faudrait alors héberger ses propres bases (`colabfold_search`, ~1 To). Pour AlphaFold Server, le risque est réel : l'équipe AlphaFold de DeepMind a été dissoute en juillet 2026 [12], et rien ne garantit que le service restera gratuit ou ouvert.

— **Protéines longues ou complexes volumineux.** Sur CPU, le temps de calcul devient prohibitif au-delà d'environ 400 résidus ; il faut alors un GPU ou Google Colab. AlphaFold Server limite aussi la taille totale d'une tâche (5 000 jetons).

— **Séquences confidentielles.** Les deux solutions envoient la séquence à un serveur externe (MSA pour ColabFold, tout le calcul pour AlphaFold Server). Elles ne conviennent donc pas à des séquences non publiées ou protégées.

— **Usage commercial.** AlphaFold Server est réservé à un usage non commercial ; une entreprise ne peut pas l'utiliser pour ses projets. AlphaFold2 (ColabFold), sous licence libre, n'a pas cette restriction.

— **Grand nombre de prédictions.** Sans API et avec 30 tâches par jour, AlphaFold Server ne permet pas de criblage à grande échelle.

— **Évolution de l'environnement.** L'image Docker de ColabFold est construite pour x86_64 et n'a pas été testée sur processeur ARM (Mac M1/M2). Si l'image ou les poids venaient à être retirés de leurs dépôts, la version figée ne pourrait plus être réinstallée.

7 Expérience de référence : la calmoduline avec AlphaFold2

Protéine choisie. La protéine étudiée est la **calmoduline-1 humaine** (*Homo sapiens*, gène *CALM1*), identifiant UniProtKB **P0DP23** [24, 23], de **149 résidus**. Voici la séquence utilisée, telle que fournie par UniProt (fichier `data/P0DP23.fasta`) :

```
MADQLTEEQIAEFKEAFSLFDKDGDGTITTKELGTVMRSLGQNPTEAELQDMINEVDADG
NGTIDFPEFLTMMARKMKDTDSEEEIREAFRVFDKDGNGYISAAELRHVMTNLGEKLTDE
                EVDEMIREADIDGDGQVNYEEFVQMMTAK
```

Ce choix a trois raisons. D'abord, la taille est compatible avec un calcul sur CPU. Ensuite, la protéine est très étudiée et sa structure expérimentale est connue (par exemple PDB 1CLL [6]). Enfin, et surtout, sa structure en « haltère » se prête bien à l'analyse des scores de confiance : deux lobes globulaires (chacun formé de deux motifs EF-hand fixant le Ca^{2+}) sont reliés par une région centrale connue pour être flexible en solution [2]. On s'attend donc à ce que le pLDDT et la PAE ne racontent pas la même chose.

Exécution. La commande `colabfold_batch --num-models 5` a été lancée avec les paramètres par défaut : MSA `mmseqs2_uniref_env`, pas de gabarits, pas de relaxation Amber, 3 recyclages. Le MSA, construit en environ 15 s, contient **21 884 séquences**. Chacun des 5 modèles a demandé environ 23 min sur CPU, soit **1 h 57 au total**. Le tableau 4 présente les fichiers importants produits dans `results/P0DP23/`.

Fichier	Contenu
`*_unrelaxed_rank_001_*.pdb`	**Structure prédite** (format PDB) du meilleur modèle ; le pLDDT est stocké dans la colonne *B-factor*
`*_scores_rank_001_*.json`	Clés `plddt` (149 valeurs), `pae` (matrice 149×149 en Å), `ptm`
`*_rank_002 ...005_*`	Les 4 autres modèles, classés par pLDDT moyen décroissant
`*.a3m, *_coverage.png`	MSA utilisé et profondeur de l'alignement par position
`log.txt, config.json`	Journal et paramètres exacts, pour la traçabilité

Table 4 – Principaux fichiers produits par ColabFold.

Structure obtenue. Le meilleur modèle (modèle 4) a un pLDDT moyen de 82,8 et un pTM de 0,487. Les 5 modèles sont très proches : pLDDT moyens entre 78,6 et 82,8, pTM entre 0,458 et 0,487. La structure (figure 3) présente bien deux lobes compacts d'hélices α, dont les centres sont distants de 32,6 Å, reliés par une région centrale étirée.

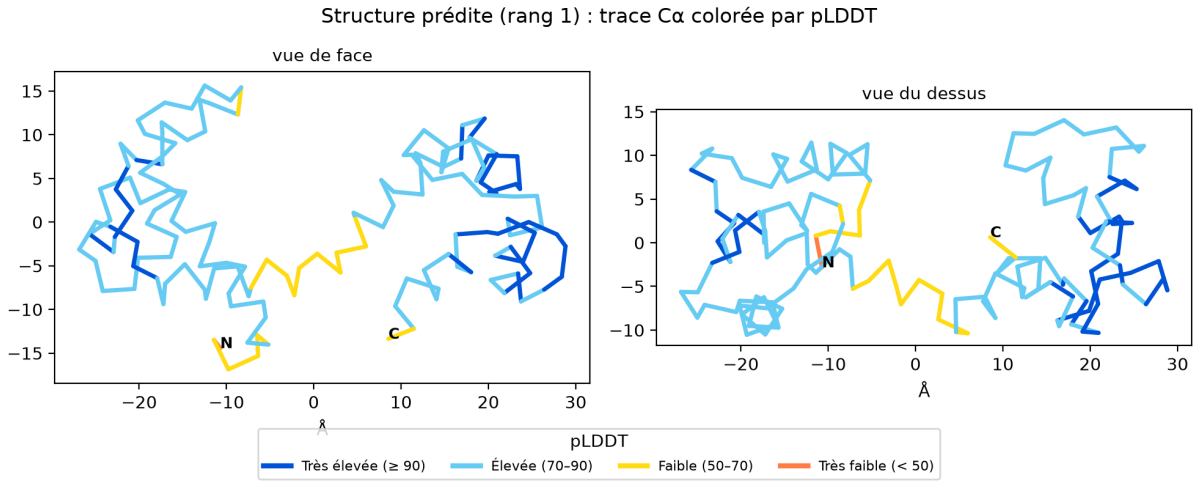


FIGURE 3 – Trace Cα du meilleur modèle, colorée par pLDDT (produite par `scripts/analyse.py`). Elle peut aussi être visualisée en 3D en déposant le fichier PDB sur `https://molstar.org/viewer/`.

8 Analyse des scores de confiance

Les deux scores se trouvent dans le fichier `*_scores_rank_001_*.json`. Le script `scripts/analyse.py` le lit avec le module `json` de Python et produit les figures ainsi qu'un résumé chiffré (`figures/P0DP23/resume.txt`). Il vérifie aussi que le pLDDT lu dans le JSON est identique à celui stocké dans la colonne B-factor du PDB (écart maximal : 0,00).

8.1 pLDDT : confiance locale

Définition. Le pLDDT (*predicted Local Distance Difference Test*) est une note de 0 à 100 attribuée à *chaque résidu*. Il estime le score lDDT-Cα [19] que la prédiction obtiendrait si on la comparait à la vraie structure. Autrement dit, il indique si les distances entre ce résidu et ses voisins proches sont correctes. Ce score est *local* et ne nécessite aucune superposition [17, 8].

- $>$ **90** : très fiable, squelette et chaînes latérales compris ;
- **70–90** : squelette fiable, chaînes latérales parfois mal placées ;
- **50–70** : faible confiance ;
- $<$ **50** : à ne pas interpréter. C'est souvent une région intrinsèquement désordonnée, mais cela peut aussi signifier que l'information manque, par exemple un linker entre deux domaines.

Le pLDDT sert donc à décider quelles parties de la structure on peut exploiter. En revanche, un pLDDT élevé partout *ne garantit pas* que les domaines sont correctement placés les uns par rapport aux autres [8].

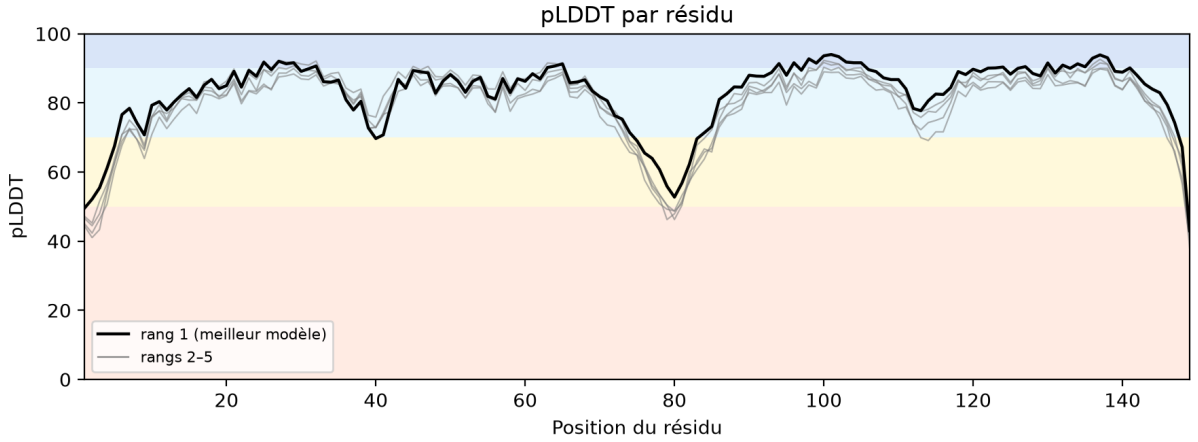


FIGURE 4 – pLDDT par résidu du meilleur modèle (noir) et des 4 autres (gris). Fonds colorés : classes de confiance.

Résultats. La figure 4 montre que 88,6 % des résidus ont un pLDDT supérieur à 70 : 21,5 % au-dessus de 90 et 67,1 % entre 70 et 90. Les deux lobes (environ 6–72 et 86–145) sont prédits avec confiance, avec des maxima au-dessus de 90 dans les hélices. Trois zones descendent sous 70 :

- **la région centrale 75–83** (minimum de 53 au résidu 80) : c'est le linker entre les deux lobes, dont la flexibilité en solution est connue [2] ;
- **les extrémités 1–5 et 148–149** (minimum de 43 au résidu C-terminal) : les extrémités libres d'une chaîne sont typiquement peu contraintes ;
- un léger creux vers le résidu 40, et un autre autour de 112–113 (environ 78), à la jonction entre les deux motifs EF-hand de chaque lobe.

Les 5 modèles donnent le même profil (courbes grises), ce qui montre que ces variations ne sont pas dues au hasard d'un seul modèle.

8.2 PAE : confiance dans les positions relatives

Définition. La PAE (*Predicted Aligned Error*) est une *matrice* N×N. La valeur (i,j) est l'erreur attendue, en ångströms, sur la position du résidu i si l'on superpose la prédiction et la vraie structure sur le résidu j [8]. Les deux axes représentent donc les résidus de la protéine : en ordonnée, le résidu dont on évalue la position ; en abscisse, le résidu sur lequel on aligne. La diagonale, qui correspond à l'alignement d'un résidu sur lui-même, vaut toujours presque zéro et ne porte pas d'information. Une valeur faible (vert foncé) signifie que la position relative des deux résidus est fiable ; une valeur élevée (vert clair) signifie qu'elle ne l'est pas.

Différence avec le pLDDT. Le pLDDT répond à la question « ce résidu est-il bien placé par rapport à ses voisins ? » ; la PAE répond à la question « la position de ce résidu *par rapport à ce résidu éloigné* est-elle fiable ? ». La PAE est donc indispensable pour juger l'**arrangement des domaines**.

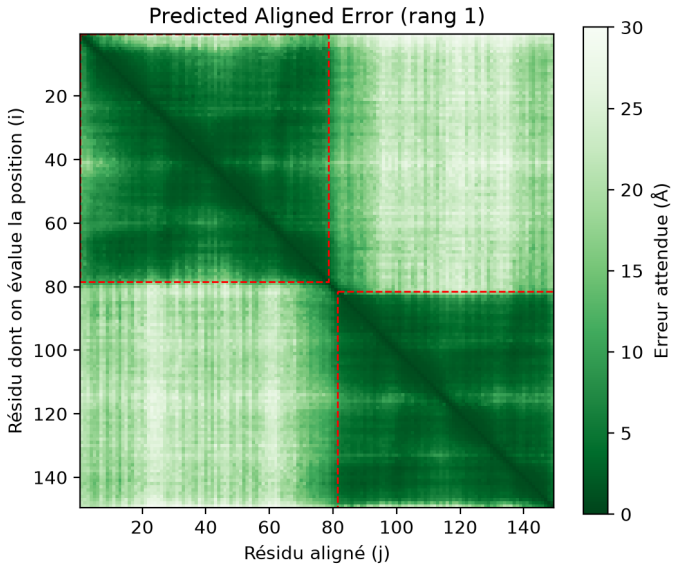


FIGURE 5 – Matrice PAE du meilleur modèle. Cadres rouges : lobe N (1–78) et lobe C (82–149).

Résultats. La matrice (figure 5) montre **deux blocs vert foncé** le long de la diagonale, qui correspondent aux deux lobes. La PAE moyenne vaut 5,1 Å à l'intérieur du lobe N et 3,8 Å à l'intérieur du lobe C : chaque lobe est une unité rigide bien prédite. En revanche, les **blocs hors diagonale** sont clairs, avec une PAE moyenne de 20,6 et 19,7 Å entre les deux lobes. AlphaFold2 est donc sûr de la forme de chaque lobe, mais *pas* de leur orientation l'une par rapport à l'autre.

C'est l'exemple typique où le pLDDT seul induirait en erreur. Hormis le linker, presque tous les résidus ont un pLDDT supérieur à 70, et pourtant la position relative des lobes dans le fichier PDB n'est qu'une conformation parmi d'autres possibles. Ce résultat est cohérent avec le pTM modeste (0,49) et avec la flexibilité connue de la calmoduline, dont la région centrale se replie pour envelopper ses peptides cibles. Enfin, AlphaFold2 ignore les ions : la structure est prédite sans les quatre Ca^{2+} qui, dans la cellule, modifient la conformation des lobes. C'est précisément l'une des limites que lève AlphaFold3, qui accepte les ions comme entités à part entière.

9 Test d'AlphaFold3 : l'ubiquitine humaine

Protéine choisie. Pour un premier essai, la protéine retenue est l'**ubiquitine humaine**, une petite protéine de 76 acides aminés dont la structure expérimentale est connue à 1,8 Å de résolution (PDB **1UBQ**). La séquence a été récupérée depuis la page « Sequence » de l'entrée 1UBQ sur le site de la PDB :

```
MQIFVKTLTGKTITLEVEPSDTIENVKAKIQDKEGIPPDQQRLIFAGKQLEDGRTLSDYNIQKES
TLHLVLRLRGG
```

Refaire la manipulation, étape par étape. Il faut seulement un navigateur et un compte Google ; aucune installation n'est nécessaire.

1. Ouvrir AlphaFold Server : `https://alphafoldserver.com/`.
2. Se connecter avec un compte Google, puis accepter les conditions d'utilisation lors de la première connexion. La page de soumission (onglet « Server ») s'affiche, avec le compteur « Remaining jobs : 30 » en haut à droite.
3. Récupérer la séquence : ouvrir `https://www.rcsb.org/fasta/entry/1UBQ` et copier son contenu, ou copier directement la séquence ci-dessus. Le champ accepte aussi le format FASTA, l'en-tête `>1UBQ_1|...` peut donc être collé avec.
4. Sur AlphaFold Server, vérifier que « Entity type » vaut *Protein* et « Copies » vaut 1, puis cliquer dans le champ « Paste sequence or fasta » (figure 6).



FIGURE 6 – Étape 4 : la ligne d'entité vide, avant de coller la séquence.

5. Coller la séquence. Le serveur l'affiche découpée par blocs de 10, avec la numérotation au-dessus.

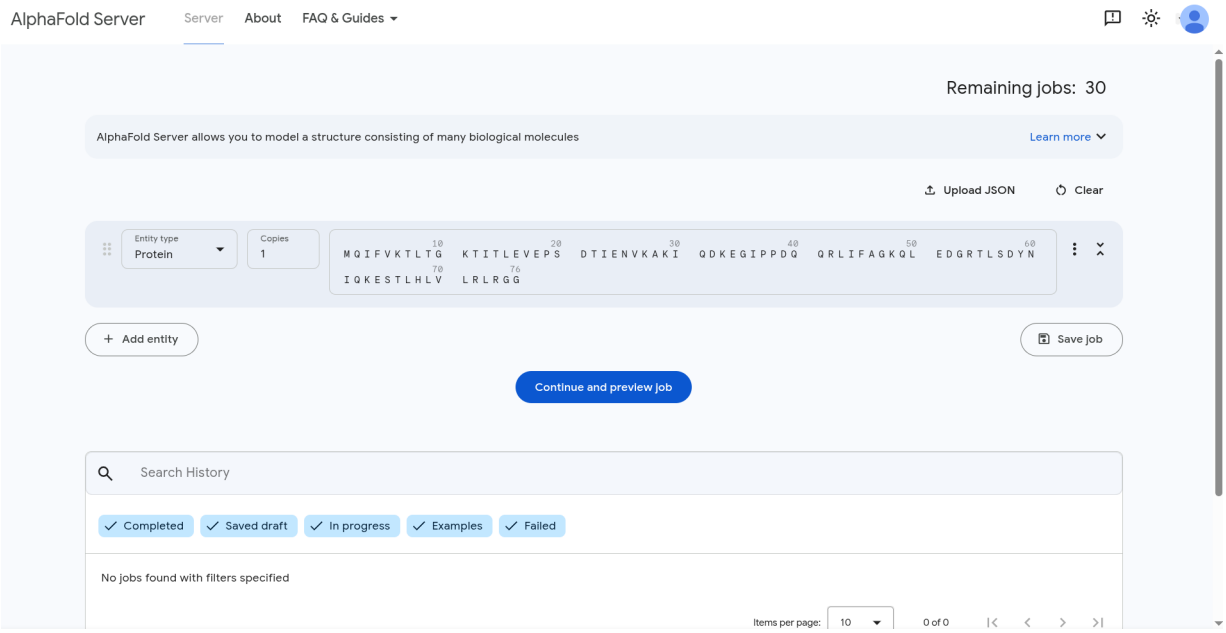


FIGURE 7 – Étape 5 : la séquence de l'ubiquitine collée (76 résidus), prête à être soumise.

6. Cliquer sur le bouton bleu « Continue and preview job ». Une fenêtre récapitulative s'ouvre (figure 8) :
   — « Job name » : le serveur propose un nom (date et heure) ; le remplacer par `ubiquitine` pour retrouver la tâche facilement ;
   — « Seed » : laisser l'interrupteur désactivé (« Seed : Auto »), le serveur tire alors une graine au hasard ;
   — vérifier le tableau : *Protein*, 1 copie, « (length 76) ».
7. Cliquer sur « Confirm and submit job ». Le compteur « Remaining jobs » diminue de 1.

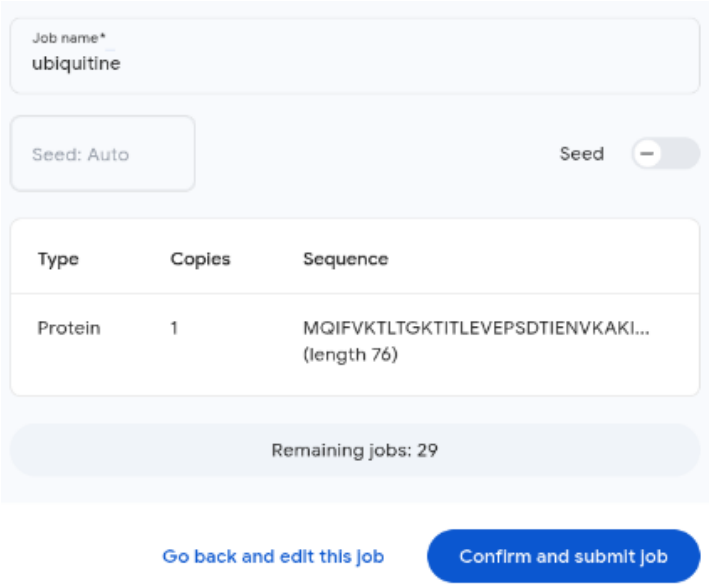


FIGURE 8 – Étapes 6 et 7 : la fenêtre de prévisualisation avant l'envoi.

8. Dans l'historique, sous le formulaire, attendre la fin du calcul (figure 9), puis cliquer sur le nom de la tâche.

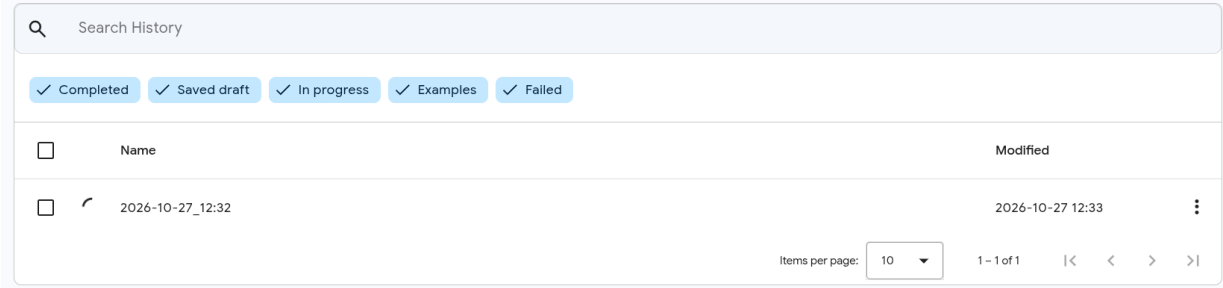


FIGURE 9 – Étape 8 : la tâche dans l'historique, en cours de calcul (icône de chargement à gauche du nom).

9. Lire le résultat : la légende des couleurs pLDDT et les scores (« ipTM = - », « pTM = 0.86 ») en haut, la structure 3D colorée par pLDDT à gauche et la matrice PAE à droite (figure 10).

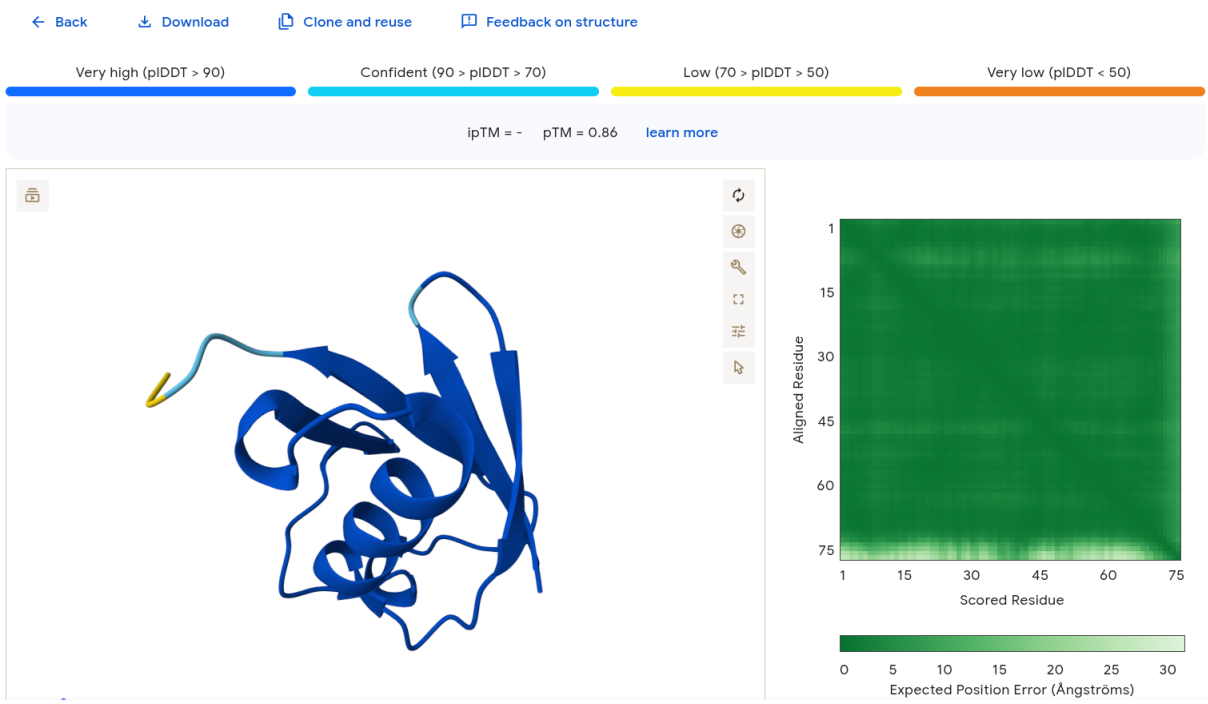


FIGURE 10 – Résultat d'AlphaFold3 (AlphaFold Server) pour l'ubiquitine : structure colorée par pLDDT (à gauche), matrice PAE (à droite) ; pTM = 0,86.

La forme. La structure (figure 10) montre un **feuillet** β qui s'enroule autour d'une **hélice** α. C'est le repliement « β-grasp », caractéristique de l'ubiquitine : compact et très stable.

Le pLDDT. La légende d'AlphaFold Server reprend les classes de confiance d'AlphaFold2 : bleu foncé ($>$ 90), bleu clair (70–90), jaune (50–70) et orange ($<$ 50). L'ubiquitine est presque entièrement bleu foncé ; seule la queue C-terminale passe au bleu clair puis au jaune. Ce résultat est cohérent avec la biologie : cette queue flexible se termine par la glycine 76, qui se lie de façon covalente aux protéines cibles lors de l'ubiquitination.

La PAE. La matrice est vert foncé presque partout : la protéine forme un seul bloc rigide, dont les positions relatives sont fiables. Seule une bande plus claire apparaît pour les résidus 72 à 76 : la position de la queue par rapport au reste de la protéine est incertaine. Sur une protéine à plusieurs domaines, on verrait au contraire plusieurs carrés foncés séparés par des zones claires, comme pour la calmoduline (figure 5).

pTM et ipTM. Le pTM vaut **0,86**, bien au-dessus du seuil de 0,5 au-delà duquel le repliement global est considéré comme correct. L'ipTM n'est pas défini ici (le serveur affiche « ipTM = - »), puisqu'il n'y a qu'une seule chaîne. Il devient le score central dès que l'on ajoute une entité (seconde protéine, ADN, ligand). Il faut aussi savoir que le score TM est très sévère pour les petites structures : sous une vingtaine de jetons, le pTM est presque nul, et il vaut mieux se fier au pLDDT et à la PAE.

10 Limites d'AlphaFold3

AlphaFold3 dépasse AlphaFold2, mais il ne règle pas tout.

— **Des hallucinations.** Un modèle de diffusion produit toujours une structure, même là où il n'y en a pas. Dans les régions désordonnées, AlphaFold3 peut dessiner une hélice ou un repliement bien ordonné qui n'existe pas en réalité. Pour limiter ce défaut, ses auteurs l'ont entraîné aussi sur des prédictions d'AlphaFold-Multimer, où ces régions apparaissent sous forme de longues boucles étirées [1]. Il faut donc toujours lire le pLDDT avant d'interpréter une région.

— **Une structure statique.** Comme AlphaFold2, AlphaFold3 prédit un état stable. Il ne donne ni la dynamique, ni les changements de conformation, ni les affinités de liaison. Il ne remplace ni l'expérience, ni la dynamique moléculaire.

— **Des chimies nouvelles mal prédites.** La précision chute quand un ligand s'éloigne chimiquement de ceux vus à l'entraînement. Les complexes anticorps–antigène restent difficiles, malgré les progrès.

— **Un accès moins ouvert.** À sa sortie, ni le code ni les poids n'étaient publiés. Depuis fin 2024, le code est disponible, mais les poids sont accordés sur demande, pour un usage académique non commercial, et ne peuvent pas être redistribués [14]. AlphaFold2, lui, reste entièrement libre.

11 Et après ? Vers un « AlphaFold 4 »

Pas d'AlphaFold 4 officiel. À la date de ce rapport, Google DeepMind n'a publié aucun modèle nommé AlphaFold 4. L'expression circule pourtant depuis février 2026, à propos d'un modèle développé par **Isomorphic Labs**, la filiale de DeepMind consacrée à la découverte de médicaments.

IsoDDE, le successeur de fait. Le 10 février 2026, Isomorphic Labs a présenté son *Drug Design Engine* (**IsoDDE**) dans un rapport technique [16]. IsoDDE reprend les capacités de prédiction de structure d'AlphaFold3 et les complète par des modules dédiés à l'affinité de liaison, à la détection de poches et aux anticorps. Le biologiste computationnel Mohammed AlQuraishi (Columbia University) le décrit comme « une avancée majeure, à l'échelle d'un AlphaFold 4 » [5].

Pourquoi il serait meilleur qu'AlphaFold3. Les gains annoncés visent précisément les limites d'AlphaFold3 décrites à la section précédente [16, 5] :

— **Des chimies nouvelles.** Sur le banc d'essai Runs N' Poses, pour les complexes protéine–ligand les plus éloignés des données d'entraînement (0 à 20 % de similarité), IsoDDE fait plus de deux fois mieux qu'AlphaFold3. Il capte aussi l'ajustement induit, c'est-à-dire la déformation de la protéine au contact du ligand.
— **Les anticorps.** Sur 334 complexes anticorps–antigène peu similaires à l'entraînement, il obtient 2,3 fois plus de prédictions de haute qualité qu'AlphaFold3.
— **L'affinité de liaison.** AlphaFold3 donne une pose, pas une force de liaison. IsoDDE prédit l'affinité, avec une précision annoncée proche des calculs physiques de référence (perturbation d'énergie libre, FEP), sans structure cristallographique de départ et pour un coût bien moindre.
— **Les poches cachées.** À partir de la seule séquence, il a retrouvé des sites de liaison connus et nouveaux sur le céréblon, dont des poches « cryptiques » qui n'apparaissent qu'en présence d'un ligand.

Autrement dit, AlphaFold3 répond à la question « comment ce complexe est-il assemblé ? ». IsoDDE vise la question suivante du pharmacologue : « cette molécule va-t-elle se fixer, où, et avec quelle force ? ».

Un progrès qu'on ne peut pas vérifier. Contrairement à AlphaFold2 et AlphaFold3, IsoDDE est **propriétaire** : ni code, ni poids, ni serveur public, et le rapport ne décrit presque pas la méthode. Il est donc impossible de reproduire ces résultats, ni de savoir s'ils viennent d'innovations dans l'algorithme ou de données privées issues des partenariats industriels [5]. Ces chiffres sont des annonces de l'entreprise, pas des résultats évalués de façon indépendante. Il faut aussi noter la nature des sources : l'expression « AlphaFold 4 » vient d'un article d'actualité de *Nature* (rubrique *News*) [5], qui rapporte l'avis de chercheurs, et non d'une publication scientifique évaluée par des pairs ; IsoDDE n'est lui-même décrit que dans un rapport technique de l'entreprise [16].

Ce qui s'est passé depuis. Huit mois après l'annonce d'IsoDDE, aucun modèle nommé AlphaFold 4 n'a été publié, ni par Google DeepMind, ni par Isomorphic Labs. Les nouvelles de 2026 vont plutôt dans le sens d'une fermeture :

— **Mars–mai 2026** : seule avancée publique, AlphaFold DB s'ouvre aux complexes. EMBL-EBI, Google DeepMind, NVIDIA et l'Université nationale de Séoul y ont ajouté 1,7 million d'homodimères et près de 80 000 hétérodimères prédits avec une confiance élevée, pour 20 espèces très étudiées et les pathogènes prioritaires de l'OMS [7]. Il s'agit de nouvelles prédictions, pas d'un nouveau modèle.
— **Mai 2026** : Isomorphic Labs lève 2,1 milliards de dollars (série B menée par Thrive Capital, avec Alphabet et GV) pour développer IsoDDE et ses propres médicaments. L'annonce ne mentionne aucune ouverture du modèle [10].
— **Juillet 2026** : Google DeepMind dissout l'équipe dédiée à AlphaFold. Ses chercheurs sont réaffectés à des projets autour de Gemini, à d'autres recherches scientifiques ou à Isomorphic Labs, et John Jumper, colauréat du prix Nobel de chimie 2024 pour AlphaFold, quitte l'entreprise [9, 12]. AlphaFold DB, AlphaFold Server et AlphaFold3 restent toutefois disponibles.

Un AlphaFold 4 public, dans la lignée des versions précédentes, semble donc peu probable à court terme.

On retrouve ainsi, en plus marqué, la tendance déjà visible avec AlphaFold3 : à chaque génération, le modèle devient plus puissant, mais moins ouvert. AlphaFold2 était entièrement libre, AlphaFold3 l'est partiellement, et son successeur de fait est réservé à un usage interne. Pour la recherche publique, les alternatives ouvertes, comme Boltz-2, prennent le relais.

12 Retour d'expérience

Ce qui a fonctionné. AlphaFold Server a rendu AlphaFold3 utilisable sans aucune installation ni GPU : une prédiction de l'ubiquitine se lance en quelques clics. Côté AlphaFold2, l'image Docker de ColabFold a fonctionné du premier coup sur une machine sans GPU, et toute la chaîne tient en deux commandes (`predict.sh` puis `analyse.py`).

Ce qui a posé problème. Le temps de calcul d'AlphaFold2 sur CPU (1 h 57 pour 149 résidus) est prohibitif au-delà de quelques centaines de résidus. Pour AlphaFold3, l'obstacle n'est plus technique mais d'accès : sans GPU de 40 à 80 Go, seul le serveur est utilisable, avec son quota, sans API et avec une liste de ligands limitée.

Recommandations.

- Pour une protéine seule, AlphaFold2 (ColabFold) reste suffisant, libre et scriptable.
- Dès que la question porte sur une interaction (ADN, ARN, ligand, ion, autre protéine), utiliser AlphaFold3 via AlphaFold Server.
- Toujours lire le pLDDT *et* la PAE avant d'interpréter la structure ; pour un complexe, regarder d'abord l'ipTM.
- Garder une trace des paramètres : graines, entités soumises, scores de confiance.

Références

[1] Josh Abramson, Jonas Adler, Jack Dunger, et al. Accurate structure prediction of biomolecular interactions with AlphaFold 3. *Nature*, 630 :493–500, 2024.

[2] Gaetano Barbato, Mitsuhiko Ikura, Lewis E. Kay, Richard W. Pastor, and Ad Bax. Backbone dynamics of calmodulin studied by 15N relaxation using inverse detected two-dimensional NMR spectroscopy : the central helix is flexible. *Biochemistry*, 31(23) :5269–5278, 1992.

[3] Helen M. Berman, John Westbrook, Zukang Feng, Gary Gilliland, T. N. Bhat, Helge Weissig, Ilya N. Shindyalov, and Philip E. Bourne. The Protein Data Bank. *Nucleic Acids Research*, 28(1) :235–242, 2000.

[4] Martin Buttenschoen, Garrett M. Morris, and Charlotte M. Deane. PoseBusters : AI-based docking methods fail to generate physically valid poses or generalise to novel sequences. *Chemical Science*, 15 :3130–3139, 2024.

[5] Ewen Callaway. 'An AlphaFold 4' – scientists marvel at DeepMind drug spin-off's exclusive new AI. *Nature*, 651(8104) :18, 2026. Article d'actualité (News), PMID 41714792. https://www.nature.com/articles/d41586-026-00365-7.

[6] Rajagopal Chattopadhyaya, William E. Meador, Anthony R. Means, and Florante A. Quiocho. Calmodulin structure refined at 1.7 å resolution. *Journal of Molecular Biology*, 228 :1177–1192, 1992.

[7] EMBL-EBI. Millions of protein complexes added to AlphaFold Database shed light on how proteins interact. https://www.ebi.ac.uk/about/news/technology-and-innovation/first-complexes-alphafold-database/, 2026. 16/03/2026, mis à jour le 19/05/2026.

[8] EMBL-EBI Training. AlphaFold : A practical guide. https://www.ebi.ac.uk/training/online/courses/alphafold/. Pages « What is the protein folding problem ? », « A high-level overview », « pLDDT : Understanding local confidence », « PAE : A measure of global confidence », « What is AlphaFold ? », « Strengths and limitations of AlphaFold 2 ». Consulté le 24/09/2026.

[9] Engadget. Google DeepMind disbands its Nobel-prize winning AlphaFold team. https://www.engadget.com/2225849/google-shuts-down-alphafold/, 2026. 30/07/2026, d'après le Financial Times.

[10] European Biotechnology Magazine. Isomorphic Labs raises $2.1B for AI-enabled drug discovery drive. https://european-biotechnology.com/latest-news/isomorphic-labs-raises-2-1b-for-ai-enabled-drug-discovery-drive/, 2026. 13/05/2026.

[11] Richard Evans, Michael O'Neill, Alexander Pritzel, et al. Protein complex prediction with AlphaFold-Multimer. *bioRxiv*, 2021. https://doi.org/10.1101/2021.10.04.463034.

[12] GIGAZINE. Google DeepMind may be disbanding its AlphaFold development team to focus on Gemini. https://gigazine.net/gsc_news/en/20260730-google-deepmind-alphafold-team/, 2026. D'après le Financial Times du 29/07/2026.

[13] Google DeepMind. AlphaFold – dépôt officiel de google deepmind. https://github.com/google-deepmind/alphafold. Section « Genetic databases » : besoins en disque et en GPU de l'installation complète.

[14] Google DeepMind. AlphaFold 3 – dépôt officiel de google deepmind. https://github.com/google-deepmind/alphafold3. Conditions d'utilisation des poids, besoins matériels et bases de données.

[15] Google DeepMind. AlphaFold Server. https://alphafoldserver.com. Pages « FAQ » et « Guides » (scores de confiance). Consulté le 05/10/2026.

[16] Isomorphic Labs. The Isomorphic Labs drug design engine (IsoDDE). Rapport technique, 2026. Publié le 10/02/2026. Résumé : https://www.biopharmatrend.com/news/isomorphic-labs-presents-an-ai-drug-design-engine-that-goes-beyond-alphafold-3-1493/.

[17] John Jumper, Richard Evans, Alexander Pritzel, et al. Highly accurate protein structure prediction with AlphaFold. *Nature*, 596 :583–589, 2021. https://doi.org/10.1038/s41586-021-03819-2.

[18] Andriy Kryshtafovych, Torsten Schwede, Maya Topf, Krzysztof Fidelis, and John Moult. Critical assessment of methods of protein structure prediction (CASP) – round XIV. *Proteins : Structure, Function, and Bioinformatics*, 89(12) :1607–1617, 2021.

[19] Valerio Mariani, Marco Biasini, Alessandro Barbato, and Torsten Schwede. lDDT : a local superposition-free score for comparing protein structures and models using distance difference tests. *Bioinformatics*, 29(21) :2722–2728, 2013.

[20] Milot Mirdita, Sergey Ovchinnikov, and Martin Steinegger. ColabFold – dépôt officiel (v1.5.5). https://github.com/sokrypton/ColabFold. Image Docker ghcr.io/sokrypton/colabfold:1.5.5-cuda12.2.2 ; notebook https://colab.research.google.com/github/sokrypton/ColabFold/blob/main/AlphaFold2.ipynb.

[21] Milot Mirdita, Konstantin Schütze, Yoshitaka Moriwaki, Lim Heo, Sergey Ovchinnikov, and Martin Steinegger. ColabFold : making protein folding accessible to all. *Nature Methods*, 19 :679–682, 2022. https://doi.org/10.1038/s41592-022-01488-1.

[22] Martin Steinegger and Johannes Söding. MMseqs2 enables sensitive protein sequence searching for the analysis of massive data sets. *Nature Biotechnology*, 35 :1026–1028, 2017.

[23] The UniProt Consortium. UniProt : the universal protein knowledgebase in 2023. *Nucleic Acids Research*, 51(D1) :D523–D531, 2023.

[24] UniProt. UniProtKB P0DP23 (CALM1_HUMAN) – calmodulin-1. https://www.uniprot.org/uniprotkb/P0DP23. Séquence FASTA : https://rest.uniprot.org/uniprotkb/P0DP23.fasta.

[25] Mihaly Varadi, Stephen Anyango, Mandar Deshpande, et al. AlphaFold protein structure database : massively expanding the structural coverage of protein-sequence space with high-accuracy models. *Nucleic Acids Research*, 50(D1) :D439–D444, 2022.

[26] Yang Zhang and Jeffrey Skolnick. Scoring function for automated assessment of protein structure template quality. *Proteins : Structure, Function, and Bioinformatics*, 57(4) :702–710, 2004.

A Annexe : le Pairformer d'AlphaFold3

Rôle. Le Pairformer est le « tronc » d'AlphaFold3 [1]. Il se place entre le module MSA et le module de diffusion (figure 2). Il ne calcule aucune coordonnée : il construit une *description* du complexe, que le module de diffusion utilise ensuite pour placer les atomes. C'est là que se fait l'essentiel du « raisonnement » sur la géométrie.

Deux représentations. Pour un complexe de N jetons, le Pairformer manipule deux tableaux de nombres :

— la **représentation par jeton** s_i : un vecteur de 384 nombres par jeton, qui résume « ce qu'est » le jeton i et son environnement ;

— la **représentation de paires** z_{ij} : un vecteur de 128 nombres pour *chaque couple* de jetons (i, j), soit une matrice $N \times N$. Elle code la relation entre les deux jetons : sont-ils proches ? à quelle distance ? dans quelle orientation ?

Au départ, z_{ij} contient ce que le réseau sait déjà : la position dans la séquence, les liaisons covalentes, les gabarits éventuels et les signaux de coévolution extraits par le module MSA. Les 48 blocs du Pairformer affinent ensuite ces deux représentations. Le tout est répété plusieurs fois par recyclage.

Contenu d'un bloc. Chaque bloc enchaîne six opérations (figure 11). Chacune ajoute une petite correction à la représentation, sans la remplacer (connexion résiduelle) :

1. **Mise à jour triangulaire multiplicative « sortante »** : z_{ij} est corrigé à partir des arêtes z_{ik} et z_{jk}, pour tous les jetons k ;
2. **Mise à jour triangulaire multiplicative « entrante »** : idem avec z_{ki} et z_{kj} ;
3. **Attention triangulaire (nœud de départ)** : la paire (i, j) choisit les paires (i, k) les plus utiles, avec un poids qui dépend de la troisième arête (j, k) ;
4. **Attention triangulaire (nœud d'arrivée)** : idem autour de j ;
5. **Transition** : un petit réseau appliqué à chaque paire séparément ;
6. **Attention sur les jetons, biaisée par les paires**, suivie d'une transition : chaque jeton i regarde les autres jetons, et l'importance qu'il accorde au jeton j dépend de z_{ij}.

Les cinq premières opérations ne travaillent que sur les paires. L'information circule ensuite des paires vers les jetons, et pas dans l'autre sens.

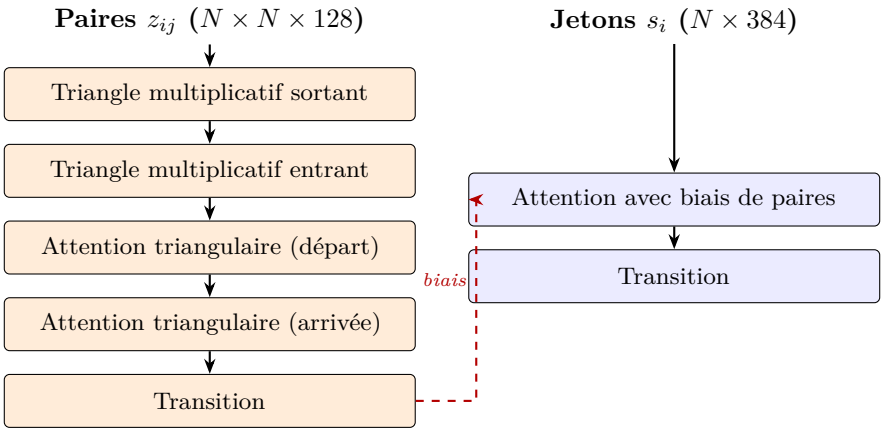


FIGURE 11 – Un bloc du Pairformer (réalisation personnelle, d'après [1]). Le Pairformer en empile 48.

Pourquoi des « triangles » ? Une liste de distances n'a de sens que si elle est *cohérente*. Pour trois points i, j, k quelconques, l'**inégalité triangulaire** impose :

$$d(i, j) \;\leq\; d(i, k) + d(k, j).$$

Si i est proche de k et k proche de j, alors i et j ne peuvent pas être loin l'un de l'autre. Les opérations triangulaires permettent au réseau d'appliquer ce genre de raisonnement : pour corriger l'arête (i, j), il consulte toutes les paires d'arêtes (i, k) et (k, j) qui forment un triangle avec elle. Il n'applique pas la formule ci-dessus telle quelle : il apprend, à partir des structures de la PDB, quelles combinaisons sont cohérentes.

Exemple : un site de fixation du calcium. L'exemple reprend la calmoduline (section 7), cette fois soumise à AlphaFold3 avec ses ions. Son premier motif EF-hand fixe un ion Ca^{2+} grâce, entre autres, à l'aspartate 21 et au glutamate 32 : un oxygène de chacune de leurs chaînes latérales se place à environ 2,4 Å de l'ion. Il suffit de considérer trois jetons : i = Asp21, j = Glu32 et k = l'ion Ca^{2+} (un atome, donc un jeton à lui seul).

Pour simplifier, il est supposé ici que z_{ij} ne contient qu'une distance estimée entre les atomes coordinants (en réalité, c'est un vecteur de 128 nombres appris, sans signification directe). Le tableau 5 montre l'état de la représentation avant et après les opérations triangulaires.

Paire	**Avant**	**Après les triangles**
Asp21 – Ca^{2+}	proche ($\approx$ 2,4 Å) : motif EF-hand reconnu	inchangé
Glu32 – Ca^{2+}	proche ($\approx$ 2,4 Å) : motif EF-hand reconnu	inchangé
Asp21 – Glu32	incertain : 11 résidus d'écart, entre 3 et 20 Å	proche : au plus 2,4 + 2,4 = 4,8 Å

TABLE 5 – Exemple simplifié de raisonnement triangulaire dans le Pairformer.

Au départ, la séquence seule ne dit pas si Asp21 et Glu32 se touchent : 11 résidus les séparent, et la boucle qui les relie pourrait être étirée. Mais le réseau a reconnu que chacun des deux touche l'ion. En passant par le jeton k, le triangle (Asp21, Ca^{2+}, Glu32) force la troisième arête : les deux résidus doivent être à moins de 5 Å l'un de l'autre. La boucle du motif EF-hand doit donc se refermer autour de l'ion. Le même raisonnement, répété sur des milliers de triangles et sur 48 blocs, propage les contraintes locales à tout le complexe. Enfin, à l'étape 6, le jeton Ca^{2+} porte son attention surtout sur Asp21, Glu32 et les autres résidus du site, ceux dont l'arête z indique qu'ils sont proches.

C'est exactement ce qu'AlphaFold2 ne pouvait pas faire : sans jeton pour l'ion, ce triangle n'existe pas, et la boucle doit être déduite de la seule coévolution.

Ce qui change par rapport à l'Evoformer. L'Evoformer d'AlphaFold2 contenait déjà les quatre opérations triangulaires. La différence porte sur le reste du bloc :

- l'Evoformer traite le MSA entier (une ligne par séquence homologue) à chaque bloc. Le Pairformer le remplace par une seule représentation par jeton, qui ne dépend pas des homologues ;
- dans l'Evoformer, le MSA met à jour les paires à chaque bloc (*outer product mean*). Dans le Pairformer, cet échange a lieu une seule fois, dans le module MSA, en amont ;
- une représentation par jeton convient à toutes les molécules. Un ligand ou un ion n'a pas d'homologues et ne pourrait pas figurer dans un MSA.

Un coût élevé. Une opération triangulaire examine, pour chacune des N^2 paires, les N jetons k possibles : son coût croît comme N^3. Doubler la taille du complexe multiplie le calcul par huit. C'est l'une des raisons pour lesquelles AlphaFold3 local demande un GPU avec beaucoup de mémoire, et pourquoi un GPU de 16 Go se limite à environ 1 280 jetons (tableau 2).